

# **DO QUE O CLIENTE RECLAMA? ANÁLISE DE SENTIMENTOS BASEADA EM ASPECTOS EM AVALIAÇÕES DE E-COMMERCE COM ROTULAGEM ASSISTIDA POR LLM**

Vitor Neves de Lima

Processamento de Linguagem Natural – Trabalho Prático Final, Etapa 1 – 2026/2

Quem compra pela internet costuma deixar, junto com a nota de uma a cinco estrelas, um comentário curto sobre a experiência. Para as lojas, esses comentários são valiosos, mas raramente são lidos em escala; o que acaba sendo acompanhado é a nota média. O problema é que a nota diz o quanto o cliente ficou satisfeito, e não por quê. Um comentário como "o produto é ótimo, mas chegou dez dias atrasado e a caixa veio amassada" elogia o produto e critica a entrega na mesma frase. Se reduzido a uma única polaridade, perde exatamente a informação que permitiria corrigir alguma coisa. Em um marketplace que reúne milhares de vendedores e transportadoras, a diferença entre "o cliente não gostou do produto" e "o produto atrasou" muda completamente quem precisa agir. Proponho tratar esse problema com Análise de Sentimentos Baseada em Aspectos (ABSA), na variante por categoria de aspecto (ACSA): para cada avaliação, o sistema deve indicar sobre quais dimensões da compra o cliente fala e se fala bem ou mal de cada uma.

O objetivo é construir e avaliar um pipeline de PLN que, dado um comentário em português, atribua a cada uma de cinco categorias (produto, entrega, condições de recebimento, anúncio e atendimento) uma polaridade positiva, negativa ou neutra, ou indique que a categoria não foi mencionada. Para chegar lá, pretendo definir a taxonomia e anotar manualmente um conjunto de referência; comparar modelos de complexidade crescente, de uma linha de base com TF-IDF até encoders Transformer em português e um LLM; testar se rótulos gerados por um LLM podem treinar um modelo bem menor sem grande perda de qualidade; e checar as previsões contra os dados de entrega dos próprios pedidos. O resultado esperado é um protótipo reproduzível, um conjunto de avaliação novo para ABSA nesse domínio e uma comparação concreta entre desempenho, custo e interpretabilidade. Ficam de fora a implantação em produção, o treinamento de modelos do zero e a extração de aspectos no nível de trechos do texto.

A motivação vem, em parte, dos experimentos feitos na disciplina. Na análise de sentimentos de tweets sobre companhias aéreas, o VADER classificou como positivo um tweet claramente irônico sobre um voo atrasado, porque a palavra "great" pesava mais do que o contexto, e mesmo a rede neural, com 87% de acurácia, ficou com F1 de apenas 0,68 na classe neutra. Ficou claro que uma polaridade única, por si só, esconde boa

parte do que o texto diz. Os dados de e-commerce reforçam isso. No corpus RePro, montado com avaliações da loja B2W, cerca de 17% das avaliações de três estrelas foram anotadas como positivas (SILVA et al., 2024), ou seja, a nota é um rótulo ruidoso. Ao mesmo tempo, uma verificação preliminar que fiz na base escolhida mostra que 73,0% dos comentários de pedidos entregues após a data estimada têm nota 1 ou 2, contra 18,5% dos pedidos entregues no prazo. A nota avisa que algo deu errado, mas só o texto diz o quê. Regras com palavras-chave também não bastam: muitos aspectos aparecem de forma implícita ("chegou antes do previsto" fala de entrega sem usar a palavra), conjunções adversativas invertem a polaridade no meio da frase e o texto é informal, com abreviações e erros de digitação. Por outro lado, classificar apenas a polaridade geral nesse tipo de base já é um problema praticamente resolvido, com ROC-AUC de 96,5 usando TF-IDF e regressão logística (SOUZA; SOUZA FILHO, 2021). O espaço para contribuir está, portanto, na granularidade, ainda mais porque há poucos recursos de ABSA em português.

Os dados virão do Brazilian E-Commerce Public Dataset, publicado pela Olist no Kaggle sob licença CC BY-NC-SA 4.0, que permite uso acadêmico (OLIST, 2018). A base tem cerca de 100 mil pedidos feitos entre 2016 e 2018 em vários marketplaces, distribuídos em tabelas relacionais. No arquivo de avaliações contei 99.224 registros, dos quais 40.950 têm comentário escrito (36.155 textos distintos). Os comentários são curtos, com média de 11,7 palavras, mediana de 9 e percentil 95 de 33. A distribuição das notas é bem desbalanceada: entre as avaliações com comentário, 50,1% têm cinco estrelas e 21,4% têm uma, enquanto as notas intermediárias somam menos de 30%. O que torna essa base mais interessante do que outros corpora de opinião é a possibilidade de cruzar cada comentário com a tabela de pedidos, que traz a data de entrega real e a data prometida, além da categoria do produto e do estado do cliente. Como fonte complementar, usarei o RePro (SILVA et al., 2024), que tem 10 mil avaliações da B2W anotadas por humanos com tópicos e polaridade. Sua taxonomia serve de ponto de partida para a minha, e os dados permitem testar se um modelo treinado em uma loja funciona na outra.

Trata-se de aprendizado supervisionado, e a tarefa é de classificação multirrótulo de textos curtos: para cada uma das cinco categorias, o modelo escolhe entre quatro classes (positivo, negativo, neutro ou não mencionado). Prefiro trabalhar com categorias predefinidas em vez de extrair os termos de aspecto do texto porque, em comentários tão curtos, grande parte dos aspectos é implícita, e categorias fixas são mais robustas e mais simples de avaliar (ZHANG et al., 2022). Como a Olist não fornece rótulos de aspecto, a supervisão terá duas origens. A primeira é um conjunto de referência de 800 comentários, sorteados com estratificação por nota e por situação de entrega para não deixar as classes raras sub-representadas, que eu mesmo anotarei seguindo um guia com exemplos

de casos difíceis. Um segundo anotador fará 200 deles, o que permite calcular o kappa de Cohen; a meta é chegar perto dos 0,68 e 0,71 obtidos no RePro. Desses 800, 300 servirão para validação e ajuste e 500 ficarão separados como teste final, sem uso em nenhuma decisão de modelagem.

A segunda origem é a rotulagem automática de cerca de 12 mil comentários por um LLM aberto, como o Qwen2.5-7B-Instruct quantizado em 4 bits, que roda no próprio Colab. O modelo receberá instruções com alguns exemplos, temperatura zero e saída em JSON, e seus rótulos serão combinados com regras simples, como listas de termos de entrega e de avaria. Há evidência de que LLMs anotam texto melhor do que trabalhadores de plataformas de crowdsourcing, a um custo bem menor (GILARDI; ALIZADEH; KUBLI, 2023). Também há evidência de que, em avaliações de produtos em português, eles erram bastante nas categorias raras (SILVA; REAL, 2024). Por isso o conjunto anotado à mão é indispensável: é com ele que vou medir quanto o LLM concorda com um humano antes de usar seus rótulos para treinar qualquer coisa.

O pré-processamento vai depender do modelo, algo que os experimentos da disciplina já mostraram na prática. Para a linha de base, os textos passarão para minúsculas, terão URLs e repetições de letras normalizadas, serão lematizados e representados por TF-IDF de unigramas e bigramas. A lista de stopwords será revisada para manter negações como "não" e "nunca", que mudam a polaridade. Sobre essa representação, treinarei regressão logística e Random Forest, um classificador por aspecto, que são rápidos e fáceis de interpretar. Para os Transformers, a limpeza será mínima: maiúsculas, pontuação e stopwords ficam, porque esses modelos têm tokenizador próprio em subpalavras, que lida melhor com erros de digitação, e foram pré-treinados em texto natural. Em ambos os casos, os nomes de lojas, que a Olist substituiu por nomes fictícios para anonimizar a base, serão trocados por um marcador genérico.

O modelo principal será o BERTimbau Base (SOUZA; NOGUEIRA; LOTUFO, 2020), com cerca de 110 milhões de parâmetros, ajustado com os rótulos do LLM. Sobre a representação do token [CLS] ficarão cinco camadas de saída, uma por aspecto, cada uma com softmax de quatro classes. Como os comentários são curtos, 128 tokens bastam para quase todos, e a configuração prevista, com taxa de aprendizado entre  $2e-5$  e  $4e-5$ , de três a cinco épocas e precisão mista, cabe na GPU gratuita do Colab. Também testarei o Albertina PT-BR de 100 milhões de parâmetros, baseado em DeBERTa (RODRIGUES et al., 2023), e uma versão do BERTimbau ajustada primeiro no RePro e depois na Olist, para medir o ganho da transferência entre lojas. O próprio LLM, aplicado direto ao teste, serve como referência de teto. A ideia de usar o LLM como "professor" de um modelo menor, e não como classificador final, se apoia em trabalhos que mostram encoders ajustados para a tarefa competindo com LLMs em análise de sentimentos es-

truturada, com custo de inferência muito menor (ZHANG et al., 2023; SIMMERING; HUOVIALA, 2023).

Toda a avaliação será feita no conjunto de teste anotado à mão. Vou reportar F1 macro por aspecto e por polaridade, F1 do par aspecto-polaridade e a matriz de confusão de cada aspecto, que mostra, por exemplo, se o modelo confunde neutro com positivo. Como o teste tem 500 exemplos, as diferenças entre modelos virão com intervalos de confiança por bootstrap e teste de McNemar, para não tomar como melhoria uma diferença que cabe na margem de erro. Também registrarei o tempo e o custo de inferência por mil avaliações, já que o argumento a favor do modelo menor é justamente esse. A parte que considero mais original é a validação com dados logísticos. Nos cerca de 39 mil comentários de pedidos entregues, vou medir, pela área sob a curva ROC, o quanto a predição de "entrega negativa" acompanha o atraso real registrado no sistema. Não espero correspondência perfeita, já que há quem reclame da entrega sem atraso formal e há atrasos que ninguém comenta, mas um resultado bem acima do acaso indica que o modelo captura o fenômeno real, e essa evidência não depende da minha anotação. Para fechar, usarei LIME (RIBEIRO; SINGH; GUESTRIN, 2016) para verificar se cada aspecto é previsto a partir de palavras que fazem sentido, como "prazo" e "chegou" para entrega, e Fairlearn (WEERTS et al., 2023) para comparar as métricas entre regiões do país e categorias de produto, já que vocabulário regional e grupos com poucos exemplos costumam piorar o desempenho. A técnica de *confident learning* (NORTHCUTT; JIANG; CHUANG, 2021) servirá ainda para estimar quantas avaliações têm nota incoerente com o texto.

Alguns problemas já são previsíveis. O desbalanceamento aparece tanto nas notas quanto nos aspectos, pois comentários sobre atendimento ou sobre o anúncio devem ser raros. Pretendo lidar com isso por meio da amostragem estratificada do conjunto de referência, de pesos por classe na função de perda e do uso do F1 macro no lugar da acurácia. A ambiguidade é outro ponto: no RePro, mais de 20% dos erros de polaridade vieram de frases com conjunções adversativas (SILVA et al., 2024), e esses casos terão uma análise de erros própria. A qualidade dos rótulos do LLM será controlada pelo ajuste das instruções no conjunto de validação, pela combinação com as regras e pela comparação direta com a anotação humana. Existe ainda o risco de contaminação, pois a base da Olist é pública desde 2018 e pode ter entrado no treinamento dos LLMs; como os rótulos de aspecto do teste serão criados neste projeto, esse risco fica sob controle, mas será mencionado. Comentários como "ok" ou "recebi" não têm conteúdo suficiente e serão tratados à parte. Do lado computacional, o Colab gratuito tem limite de sessão e de cota de GPU, então os pontos de verificação ficarão no Google Drive, todas as respostas do LLM serão guardadas em cache e a rotulagem será feita em lotes ao longo de várias sessões. Se o modelo de 7 bilhões de parâmetros for lento demais, a alternativa é um mode-

lo de 3 a 4 bilhões ou a API do Sabiá-3, de baixo custo (ABONIZIO et al., 2024). Se os rótulos das categorias raras ficarem ruins, reduzo a taxonomia para quatro aspectos.

O projeto cabe em três meses usando apenas o Colab gratuito ou um computador comum: o arquivo de avaliações tem menos de 15 MB e o ajuste fino de um encoder base sobre alguns milhares de textos curtos leva dezenas de minutos em uma GPU T4. No primeiro mês, faço a exploração e o cruzamento das tabelas, defino a taxonomia e o guia, anoto o conjunto de referência (estimo entre 15 e 25 horas de trabalho) e implemento a linha de base. No segundo, rodo a rotulagem com o LLM e treino e avalio o BERTimbau, o Albertina e a versão com transferência. No terceiro, faço a validação com os dados de entrega, as análises de explicabilidade, de equidade e de erros, e escrevo o relatório. Se tudo correr como planejado, o trabalho deve mostrar que dá para transformar dezenas de milhares de comentários soltos em um mapa de motivos de insatisfação por aspecto, categoria de produto e região. Deve mostrar também se a combinação de rótulos gerados por LLM, uma anotação humana pequena e um encoder em português é uma alternativa viável à anotação manual em grande escala.

## REFERÊNCIAS

- ABONIZIO, H. et al. **Sabiá-3 Technical Report**. arXiv:2410.12049, 2024. Disponível em: <https://arxiv.org/abs/2410.12049>. Acesso em: 8 out. 2026.
- GILARDI, F.; ALIZADEH, M.; KUBLI, M. ChatGPT outperforms crowd workers for text-annotation tasks. **Proceedings of the National Academy of Sciences**, v. 120, n. 30, e2305016120, 2023. DOI: 10.1073/pnas.2305016120.
- NORTHCUTT, C.; JIANG, L.; CHUANG, I. Confident learning: estimating uncertainty in dataset labels. **Journal of Artificial Intelligence Research**, v. 70, p. 1373-1411, 2021.
- OLIST. **Brazilian E-Commerce Public Dataset by Olist**. Kaggle, 2018. Licença CC BY-NC-SA 4.0. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 8 out. 2026.
- RIBEIRO, M. T.; SINGH, S.; GUESTIN, C. "Why should I trust you?": explaining the predictions of any classifier. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. **Proceedings** [...]. New York: ACM, 2016. p. 1135-1144.
- RODRIGUES, J. et al. **Advancing neural encoding of Portuguese with Transformer Albertina PT-\***. arXiv:2305.06721, 2023. Disponível em: <https://arxiv.org/abs/2305.06721>. Acesso em: 8 out. 2026.
- SILVA, L. N. dos S. et al. RePro: a benchmark dataset for opinion mining in Brazilian Portuguese. In: INTERNATIONAL CONFERENCE ON COMPUTATIONAL PROCESSING OF PORTUGUESE (PROPOR), 16., 2024, Santiago de Compostela. **Proceedings** [...]. ACL, 2024. v. 1, p. 432-440. Disponível em: <https://aclanthology.org/2024.propor-1.44/>. Acesso em: 8 out. 2026.
- SILVA, L. N. dos S.; REAL, L. Automated topic annotation in Brazilian product reviews: a case study of adversarial examples with Sabiá-3. In: SIMPÓSIO BRASILEIRO DE TECNOLOGIA

DA INFORMAÇÃO E DA LINGUAGEM HUMANA (STIL), 15., 2024, Belém. **Anais [...]**. Porto Alegre: SBC, 2024. p. 484-492. DOI: 10.5753/stil.2024.31167.

SIMMERING, P. F.; HUOVIALA, P. **Large language models for aspect-based sentiment analysis**. arXiv:2310.18025, 2023. Disponível em: <https://arxiv.org/abs/2310.18025>. Acesso em: 8 out. 2026.

SOUZA, F. D.; SOUZA FILHO, J. B. O. **Sentiment analysis on Brazilian Portuguese user reviews**. In: IEEE LATIN AMERICAN CONFERENCE ON COMPUTATIONAL INTELLIGENCE (LA-CCI), 2021. arXiv:2112.05459. Disponível em: <https://arxiv.org/abs/2112.05459>. Acesso em: 8 out. 2026.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: CERRI, R.; PRATI, R. C. (ed.). **Intelligent Systems – BRACIS 2020**. Cham: Springer, 2020. p. 403-417. DOI: 10.1007/978-3-030-61377-8\_28.

WEERTS, H. et al. Fairlearn: assessing and improving fairness of AI systems. **Journal of Machine Learning Research**, v. 24, n. 257, p. 1-8, 2023.

ZHANG, W. et al. **A survey on aspect-based sentiment analysis: tasks, methods, and challenges**. arXiv:2203.01054, 2022. Disponível em: <https://arxiv.org/abs/2203.01054>. Acesso em: 8 out. 2026.

ZHANG, W. et al. **Sentiment analysis in the era of large language models: a reality check**. arXiv:2305.15005, 2023. Disponível em: <https://arxiv.org/abs/2305.15005>. Acesso em: 8 out. 2026.